

Omar Alexis Becerra Sierra

Senior Data Engineer · Azure Databricks & Lakehouse

Área metropolitana de Medellín, Colombia · Disponible en remoto · (+57) 314 299 1192 · omarbecerrasierra@gmail.com

linkedin.com/in/omarbecerrasierra · github.com/omarbecerrasierra · omarbecerrasierra.github.io

ORCID 0009-0004-6376-5649 · [Google Scholar](https://scholar.google.com/citations?user=...)

PERFIL PROFESIONAL

Convierto prototipos de datos en plataformas confiables, gobernadas y listas para producción. **Senior Data Engineer** con **seis años** en datos e inteligencia artificial; desde 2025 enfocado en **banca y servicios financieros en LatAm**, diseñando arquitecturas **Lakehouse** sobre **Azure Databricks** donde la trazabilidad, la calidad y el control de acceso son críticos. He operado plataformas de decenas de millones de registros diarios, migraciones desde sistemas heredados y pipelines para modelos de riesgo crediticio. **MSc en Matemáticas Aplicadas** y tres publicaciones indexadas: entiendo no solo cuándo falla una solución, sino por qué y cómo corregirla.

HABILIDADES TÉCNICAS

Data Engineering Azure Databricks, Apache Spark, PySpark, Spark Structured Streaming, Delta Lake, Lakeflow Declarative Pipelines (Delta Live Tables), Lakeflow Jobs (Workflows), Unity Catalog, Azure Data Factory, ADLS Gen2, SQL Server, SQL avanzado, PostgreSQL, Kafka, Airflow, dbt, modelado dimensional, esquema estrella, arquitectura medallion, migración de datos.

Cloud y MLOps Microsoft Azure, AWS, MLflow (Tracking y Model Registry), Docker, Terraform, Git, CI/CD con Azure DevOps, monitoreo de *data drift*, calidad de datos, gobierno y linaje de datos, optimización de costos (FinOps).

Machine Learning e IA Python, Scikit-learn, Pandas, Keras, LLMs (OpenAI, Gemini), NLP, RAG, LangChain, búsqueda vectorial, *feature stores*, modelos de riesgo crediticio, modelos basados en grafos.

Matemáticas aplicadas Estadística robusta y no paramétrica, series de tiempo, optimización combinatoria, modelado estocástico, datos sintéticos, estadística espacial.

Idiomas Español (nativo) · Inglés (competencia profesional básica; lectura técnica fluida).

EXPERIENCIA PROFESIONAL

iData Global

feb. 2026 – Actualidad

Senior Data Engineer · Medellín, Colombia · Remoto

Consultora de datos e IA (partner de Microsoft y Databricks, 300+ clientes en América). Migración desde SQL Server hacia arquitectura Lakehouse en Azure Databricks para el sector financiero.

- Diseño y mantengo pipelines de ingesta y orquestación con **Azure Data Factory**, con cargas completas e incrementales.
- Desarrollo transformaciones con **PySpark** y **Delta Lake** sobre Azure Databricks.
- Análisis de tablas, esquemas y dependencias del origen para planificar cada ola de migración sin interrumpir la operación.
- Implemento controles de calidad y validaciones de consistencia entre origen y destino, condición previa a cada corte productivo.
- Monitoreo la ejecución de los pipelines, gestiono errores, documento los flujos y apoyo el despliegue en producción.

Stack: Azure Databricks · Azure Data Factory · PySpark · Delta Lake · SQL Server · SQL · Python · Git

Indra

mar. 2025 – feb. 2026

Senior Cloud Data Engineer · Medellín, Colombia · Remoto

Ingeniería de datos cloud para banca dentro de la práctica de Data & Analytics.

- Diseñé y operé pipelines de ingesta y transformación en **Azure Databricks** con **Delta Lake** y **Delta Live Tables** (hoy Lakeflow Declarative Pipelines), procesando **10 millones de registros diarios** desde bases *on-premise* hacia **ADLS Gen2**.
- Implementé gobierno de datos con **Unity Catalog** —linaje, control de acceso y catálogo certificado—, habilitando el consumo de datos gobernados sin intervención del equipo de plataforma.
- Modelé la capa analítica en **esquema estrella** sobre PostgreSQL y Delta, soportando **15 tableros de negocio**.
- Orquesté cargas con **Azure Data Factory** y **Databricks Workflows**, con versionamiento en **Git** y despliegue vía **Azure DevOps**, reduciendo el tiempo de puesta en producción de nuevos pipelines.
- Optimicé costos de cómputo en Databricks mediante dimensionamiento de clústeres y ajuste de particionamiento.

Stack: Azure Databricks · PySpark · Delta Lake · Delta Live Tables · Unity Catalog · Azure Data Factory · ADLS Gen2 · PostgreSQL · Terraform · Git · Azure DevOps

BIKY.ai

feb. 2022 – feb. 2025

Senior Cloud Data Engineer · California, Estados Unidos · Remoto

Plataforma de CRM e IA conversacional con clientes en LatAm y Estados Unidos. Equipo remoto distribuido.

- Construí y mantuve el módulo de métricas que consolidaba los datos de CRM de cerca de **400 empresas cliente**, unificando **5 fuentes heterogéneas** en un modelo común.
- Desarrollé pipelines de streaming con **Spark Structured Streaming** y **Kafka** para ingesta de mensajes, sosteniendo **10 millones de eventos diarios** con latencia de **100 ms**.
- Implementé modelos de NLP y LLMs (OpenAI, Gemini) para clasificación automática de conversaciones.
- Establecí prácticas de **MLOps** con **MLflow** (tracking y registro), eliminando el despliegue de modelos sin trazabilidad.

Stack: Python · PySpark · Kafka · Delta Lake · Keras · LangChain · Vector Search · MLflow · Docker · AWS

Grupo Éxito

sept. 2020 – feb. 2022

Medellín, Colombia

Data Engineer & Data Scientist — Kiire

jun. 2021 – feb. 2022

- Administré pipelines y almacenamiento que procesaban más de **100 millones de registros diarios**, garantizando disponibilidad del dato para análisis y decisión.
- Lideré cerca de **10 proyectos** de distintos ámbitos: modelos basados en grafos, machine learning para predicción del desempeño de campañas y modelos de IA para redireccionar campañas en curso.
- Administré una plataforma cloud escalable y desarrollé tableros que dieron visibilidad del negocio e identificaron áreas de mejora para la toma de decisiones.

Aprendiz en prácticas — Analítica Digital

sept. 2020 – jun. 2021

- Desarrollé un software de enrutamiento de vehículos que optimizó las rutas de entrega de una operación logística de gran escala.
- Construí un pipeline para calcular la **elasticidad demanda-precio**, anticipando el efecto de cambios de precio sobre la demanda. Apliqué ML e IA en finanzas, retail, mercancías y TI.

Universidad EAFIT

sept. 2020 – feb. 2021

Consultor en Ciencia de Datos Senior · Jornada parcial · Remoto

- Apliqué métodos estadísticos y de machine learning en proyectos del Grupo de Modelado Matemático (datos sintéticos, estadística robusta, optimización). Trabajo derivado en las publicaciones listadas abajo.

INVESTIGACIÓN INDEPENDIENTE Y PUBLICACIONES

Estadística robusta no paramétrica y análisis espacial

2020 – Actualidad

Investigador independiente · En colaboración con investigadores de universidades colombianas

Líneas activas: estimadores robustos y detección de *outliers* multivariados en alta dimensión; generación no paramétrica de datos sintéticos mediante cópulas empíricas; análisis estadístico espacial aplicado a seguridad ciudadana.

- Ortiz, S., **Becerra, O.** (2024). On a Stahel–Donoho estimator with skewness-based random projection directions. *Chilean Journal of Statistics*, 15(2), 110–125. doi.org/10.32372/chjs.15-02-01
- Restrepo, J. P., Rivera, J. C., Laniado, H., Osorio, P., **Becerra, O. A.** (2023). Nonparametric Generation of Synthetic Data Using Copulas. *Electronics* (MDPI), 12(7), 1601. doi.org/10.3390/electronics12071601
- García Jiménez, M. E., **Becerra Sierra, O. A.**, Rivera, J. C. (2021). Un algoritmo evolutivo híbrido para el problema de programación del taller de flujo permutado con restricciones de turno. *Ingeniare. Revista chilena de ingeniería*, 29(3), 546–556. doi.org/10.4067/S0718-33052021000300546

EDUCACIÓN

Universidad EAFIT

ene. 2022 – jun. 2024

Maestría en Matemáticas Aplicadas — énfasis en Estadística y Machine Learning · Medellín, Colombia

Universidad EAFIT

2017 – 2021

Ingeniería Matemática — modelado matemático y métodos computacionales · Medellín, Colombia